Regresión Lineal Múltiple Mejorada: Predicción de Emisiones de CO_2

✅ 1. Objetivos

- Ampliar el modelo de regresión lineal múltiple anterior incorporando nuevas variables.
- Probar modelos no lineales como Árboles de Decisión y Random Forest.
- Evaluar y tratar outliers para mejorar la precisión.
- Aplicar validación cruzada para evaluar la generalización del modelo.

✅ 2. Carga y exploración de datos

Cargar los datos

```
# Importar librerias
import pandas as pd
import numpy as np
```

```
file_path = '/content/drive/MyDrive/FuelConsumptionCo2.csv'
df = pd.read_csv(file_path)
```

```
# Mostrar las primeras 5 filas del dataframe con el método dataframe.head()
df.head()
```

	MODELYEAR	MAKE	MODEL	VEHICLECLASS	ENGINESIZE	CYLINDERS	TRANSMISSION	FUELTYPE	FUELCONSUMPTION_CITY	FUELCONSU
0	2014	ACURA	ILX	COMPACT	2.0	4	AS5	Z	9.9	
1	2014	ACURA	ILX	COMPACT	2.4	4	M6	Z	11.2	
2	2014	ACURA	ILX HYBRID	COMPACT	1.5	4	AV7	Z	6.0	
3	2014	ACURA	MDX 4WD	SUV - SMALL	3.5	6	AS6	Z	12.7	

Next steps: Generate code with df | View recommended plots | New interactive sheet

Exploración de datos

Usa df.describe() y df.info() para entender los datos.

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1067 entries, 0 to 1066
Data columns (total 13 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   MODELYEAR                 1067 non-null   int64
 1   MAKE                      1067 non-null   object
 2   MODEL                     1067 non-null   object
 3   VEHICLECLASS              1067 non-null   object
 4   ENGINESIZE                1067 non-null   float64
 5   CYLINDERS                 1067 non-null   int64
 6   TRANSMISSION              1067 non-null   object
 7   FUELTYPE                  1067 non-null   object
 8   FUELCONSUMPTION_CITY      1067 non-null   float64
```

```
 9   FUELCONSUMPTION_HWY       1067 non-null   float64
 10  FUELCONSUMPTION_COMB      1067 non-null   float64
 11  FUELCONSUMPTION_COMB_MPG  1067 non-null   int64
 12  CO2EMISSIONS              1067 non-null   int64
dtypes: float64(4), int64(4), object(5)
memory usage: 108.5+ KB
```

```
df.describe()
```

	MODELYEAR	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_CITY	FUELCONSUMPTION_HWY	FUELCONSUMPTION_COMB	FUELCONSUMPTION
count	1067.0	1067.000000	1067.000000	1067.000000	1067.000000	1067.000000	1(
mean	2014.0	3.346298	5.794752	13.296532	9.474602	11.580881	
std	0.0	1.415895	1.797447	4.101253	2.794510	3.485595	
min	2014.0	1.000000	3.000000	4.600000	4.900000	4.700000	
25%	2014.0	2.000000	4.000000	10.250000	7.500000	9.000000	
50%	2014.0	3.400000	6.000000	12.600000	8.800000	10.900000	
75%	2014.0	4.300000	8.000000	15.550000	10.850000	13.350000	
max	2014.0	8.400000	12.000000	30.200000	20.500000	25.800000	

Evaluación de datos faltantes

```
missing_values = df.isnull().sum()
print(missing_values)
```

```
MODELYEAR                 0
MAKE                      0
MODEL                     0
VEHICLECLASS              0
ENGINESIZE                0
CYLINDERS                 0
TRANSMISSION              0
FUELTYPE                  0
FUELCONSUMPTION_CITY      0
FUELCONSUMPTION_HWY       0
FUELCONSUMPTION_COMB      0
FUELCONSUMPTION_COMB_MPG  0
CO2EMISSIONS              0
dtype: int64
```

Explorar distribución y correlación entre las variables `ENGINESIZE`, `CYLINDERS`, `FUELCONSUMPTION_COMB` y `CO2EMISSIONS`

```
import matplotlib.pyplot as plt
import seaborn as sns


sns.pairplot(df[['ENGINESIZE', 'CYLINDERS', 'FUELCONSUMPTION_COMB', 'CO2EMISSIONS']])
plt.show()
```

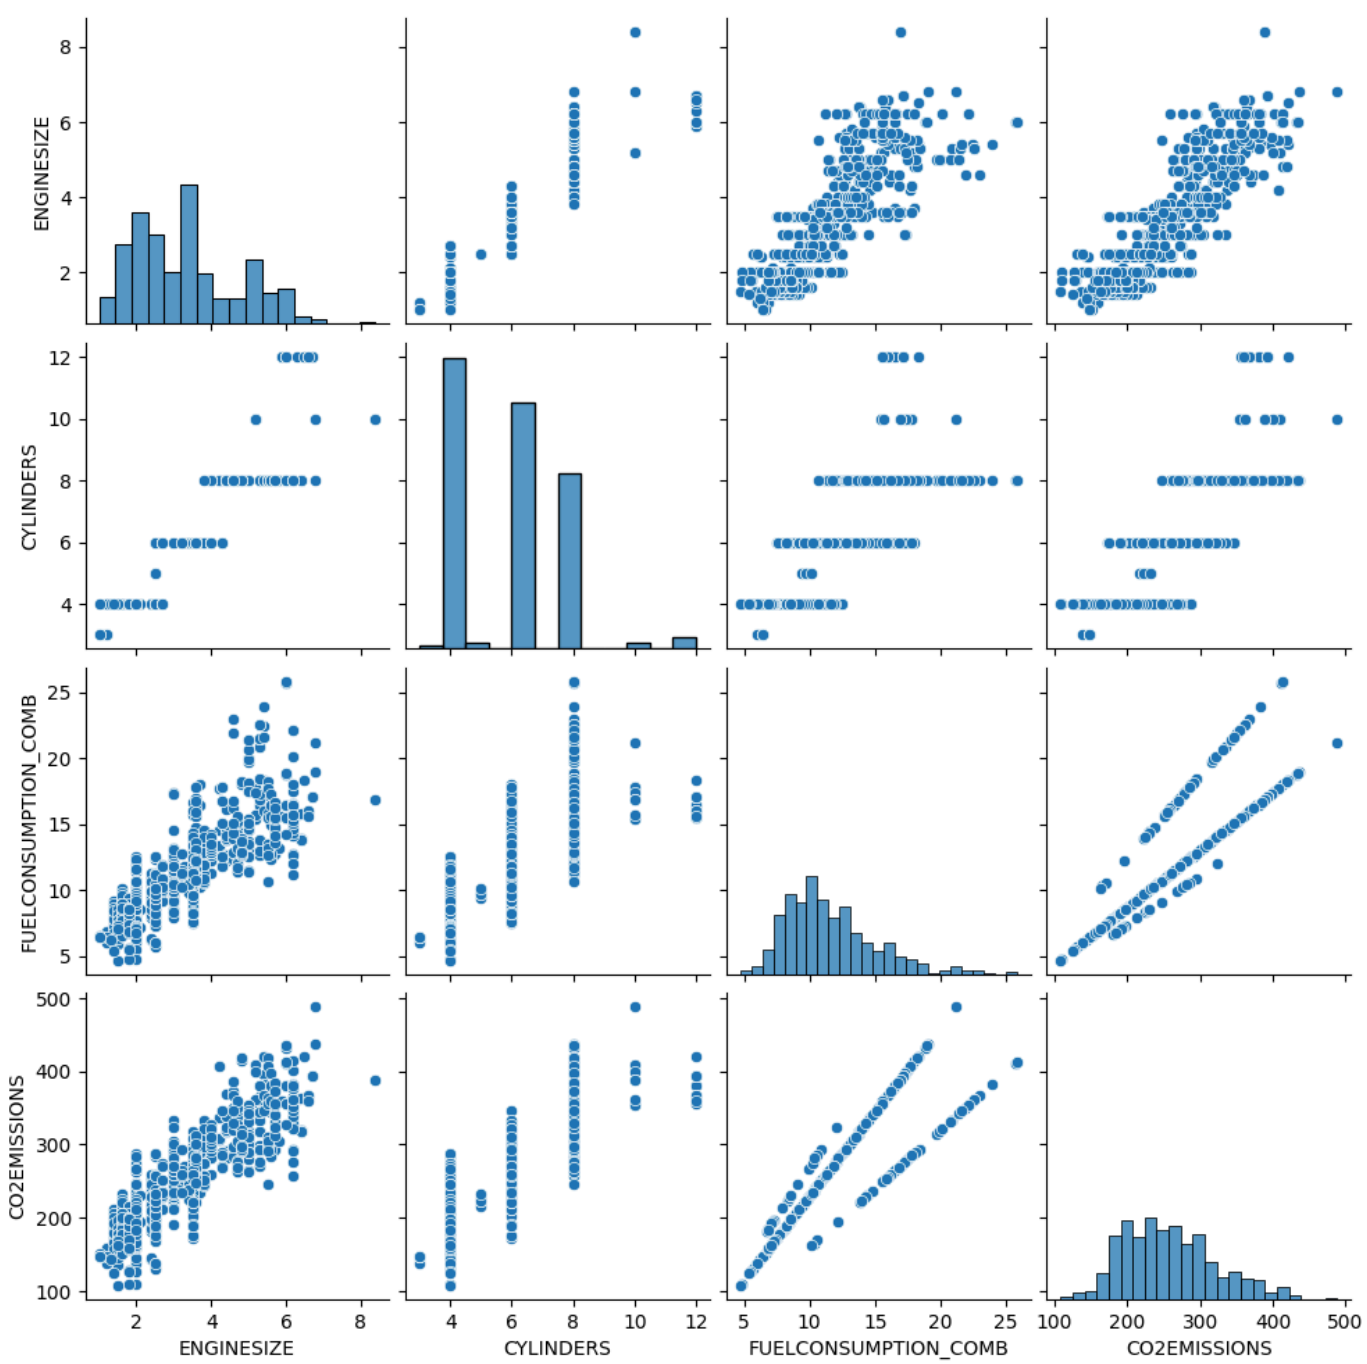

Calcula la matriz de correlación para elegir las variables más relacionadas con `CO2EMISSIONS`.

```
correlation = df.select_dtypes(include=np.number).corr()
sns.heatmap(correlation, annot=True, cmap='coolwarm')
plt.show()
```

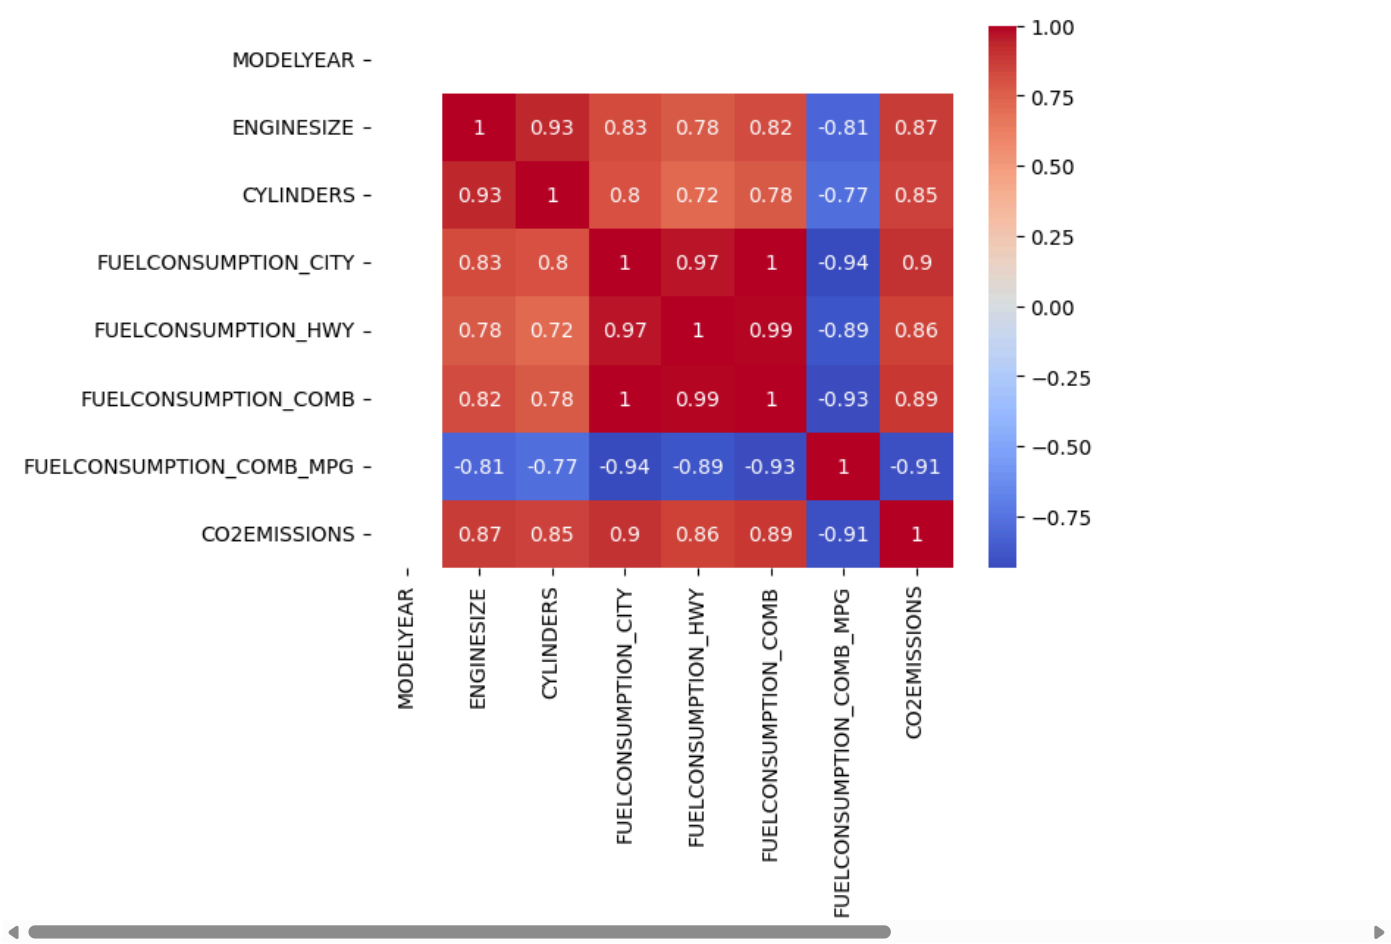

✅ 3. Limpieza y tratamiento de outliers

Se analizarán las distribuciones y se eliminarán o transformarán valores atípicos que puedan afectar el rendimiento del modelo.

📊 Análisis de outliers mediante boxplots

En esta sección se generó una cuadrícula de boxplots para todas las variables numéricas del dataset con el objetivo de identificar visualmente la presencia de valores atípicos (outliers).

```
# Seleccionar las columnas numéricas para el gráfico
numerical_cols = ['ENGINESIZE', 'CYLINDERS', 'FUELCONSUMPTION_CITY', 'FUELCONSUMPTION_HWY', 'FUELCONSUMPTION_COMB', 'FUELCC

# Determina el número de filas y columnas de la cuadrícula para el diseño horizontal
n_rows = 3 # Puede ajustar el número de filas según sea necesario
n_cols = (len(numerical_cols) + n_rows - 1) // n_rows # Calcular el número de columnas necesarias

# Crea una figura y una cuadrícula de subplots
fig, axes = plt.subplots(n_rows, n_cols, figsize=(n_cols * 5, 5)) # Ajustar el tamaño de la figura para el diseño horizonta

# Aplana la matriz de ejes para facilitar iteración
axes = axes.flatten()

# Crea un diagrama de caja para cada columna numérica en su subplot respectivo
for i, col in enumerate(numerical_cols):
    sns.boxplot(x=df[col], ax=axes[i], color='skyblue') # Traza horizontalmente usando x
    axes[i].set_title(col) # Establece el título para cada subplot
    axes[i].set_xlabel('') # Elimina la etiqueta predeterminada del eje x

# Ocultar los subgráficos no utilizados
for j in range(i + 1, len(axes)):
```

```
    fig.delaxes(axes[j])

plt.tight_layout() # Ajusta el diseño para evitar que las etiquetas se superpongan
plt.show()
```

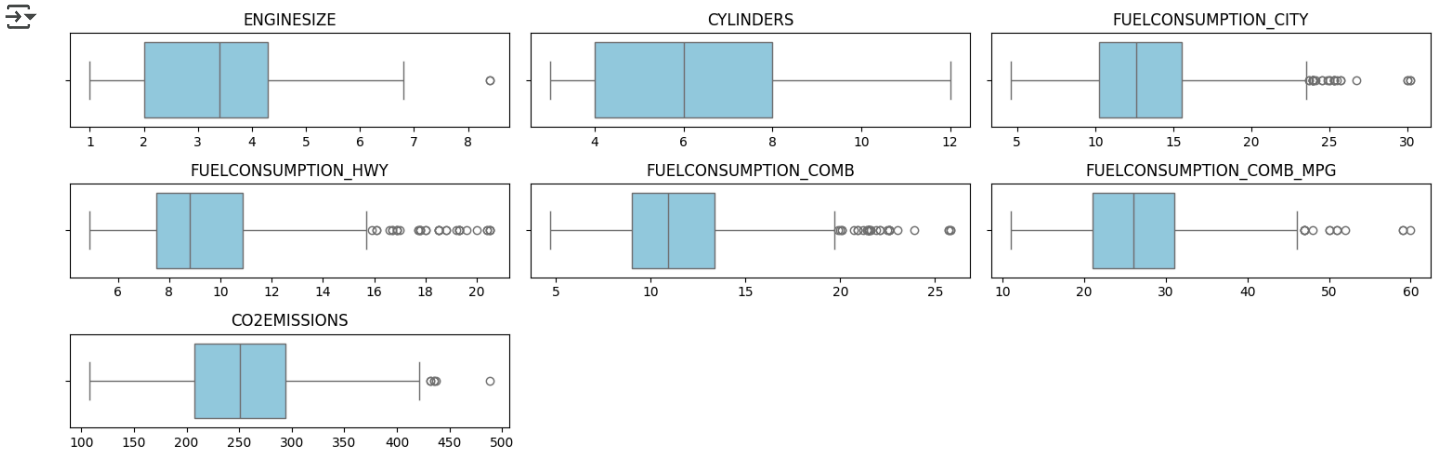

🔍 **Observaciones clave**:

`ENGINESIZE` y `CYLINDERS` presentan valores extremos en el rango superior, correspondientes a vehículos con motores muy grandes o configuraciones poco comunes (*por ejemplo, 10 o 12 cilindros*).

Las variables de consumo de combustible (`FUELCONSUMPTION_CITY`, `HWY`, `COMB`) muestran una distribución sesgada hacia la derecha, con algunos vehículos que consumen significativamente más combustible que el promedio.

`CO2EMISSIONS` también presenta outliers en el extremo superior, lo cual es esperable en vehículos de alto rendimiento o gran tamaño.

Otras variables como `FUELCONSUMPTION_COMB_MPG` muestran outliers en el extremo inferior, lo que indica bajo rendimiento de combustible (*más emisiones*).

✅ **Conclusión**:

Este análisis visual respalda la necesidad de aplicar una técnica de limpieza como el método del rango intercuartílico (IQR) para eliminar estos valores extremos antes de entrenar los modelos. Esto ayudará a mejorar la estabilidad y precisión de las predicciones.

📊 Análisis de la Distribución de Variables Numéricas

[ ] ↳ 3 cells hidden

Limpieza y tratamiento de outliers

En esta sección aplicamos el método del rango intercuartílico (IQR) para detectar y eliminar valores atípicos en las variables numéricas del dataset. Esto ayuda a mejorar la precisión del modelo al reducir el impacto de valores extremos que podrían sesgar los resultados.

```
# Seleccionar columnas numéricas
numeric_cols = df.select_dtypes(include=['float64', 'int64']).columns

# Función para eliminar outliers usando el método IQR
def remove_outliers_iqr(data, columns):
    df_clean = data.copy()
```

```
    for col in columns:
        Q1 = df_clean[col].quantile(0.25)
        Q3 = df_clean[col].quantile(0.75)
        IQR = Q3 - Q1
        lower_bound = Q1 - 1.5 * IQR
        upper_bound = Q3 + 1.5 * IQR
        df_clean = df_clean[(df_clean[col] >= lower_bound) & (df_clean[col] <= upper_bound)]
    return df_clean

# Aplicar la función al dataset
df_cleaned = remove_outliers_iqr(df, numeric_cols)

# Mostrar el número de filas antes y después de la limpieza
print(f"Número de filas antes de eliminar outliers: {df.shape[0]}")
print(f"Número de filas después de eliminar outliers: {df_cleaned.shape[0]}")

```

```
Número de filas antes de eliminar outliers: 1067
Número de filas después de eliminar outliers: 998
```

Se eliminaron 69 registros con valores atípicos.

✅ 4. Ingeniería de variables

Se codificarán variables categóricas como `FUELTYPE`, `TRANSMISSION` y `VEHICLECLASS` usando One-Hot Encoding.

```
df_cleaned = pd.get_dummies(df_cleaned, columns=['FUELTYPE', 'TRANSMISSION', 'VEHICLECLASS'], dtype=int)
display(df_cleaned.head())
```

	MODELYEAR	MAKE	MODEL	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_CITY	FUELCONSUMPTION_HWY	FUELCONSUMPTION_COMB	FUELCO
0	2014	ACURA	ILX	2.0	4	9.9	6.7	8.5	
1	2014	ACURA	ILX	2.4	4	11.2	7.7	9.6	
3	2014	ACURA	MDX 4WD	3.5	6	12.7	9.1	11.1	
4	2014	ACURA	RDX AWD	3.5	6	12.1	8.7	10.6	
5	2014	ACURA	RLX	3.5	6	11.9	7.7	10.0	

5 rows × 52 columns

```
df_cleaned.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 998 entries, 0 to 1066
Data columns (total 52 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   MODELYEAR                       998 non-null    int64
 1   MAKE                            998 non-null    object
 2   MODEL                           998 non-null    object
 3   ENGINESIZE                      998 non-null    float64
 4   CYLINDERS                       998 non-null    int64
 5   FUELCONSUMPTION_CITY            998 non-null    float64
 6   FUELCONSUMPTION_HWY             998 non-null    float64
 7   FUELCONSUMPTION_COMB            998 non-null    float64
 8   FUELCONSUMPTION_COMB_MPG        998 non-null    int64
 9   CO2EMISSIONS                    998 non-null    int64
 10  FUELTYPE_D                      998 non-null    int64
 11  FUELTYPE_E                      998 non-null    int64
 12  FUELTYPE_X                      998 non-null    int64
 13  FUELTYPE_Z                      998 non-null    int64
 14  TRANSMISSION_A4                 998 non-null    int64
```

```
 16  TRANSMISSION_A6                       998 non-null    int64
 17  TRANSMISSION_A7                       998 non-null    int64
 18  TRANSMISSION_A8                       998 non-null    int64
 19  TRANSMISSION_A9                       998 non-null    int64
 20  TRANSMISSION_AM5                      998 non-null    int64
 21  TRANSMISSION_AM6                      998 non-null    int64
 22  TRANSMISSION_AM7                      998 non-null    int64
 23  TRANSMISSION_AS4                      998 non-null    int64
 24  TRANSMISSION_AS5                      998 non-null    int64
 25  TRANSMISSION_AS6                      998 non-null    int64
 26  TRANSMISSION_AS7                      998 non-null    int64
 27  TRANSMISSION_AS8                      998 non-null    int64
 28  TRANSMISSION_AS9                      998 non-null    int64
 29  TRANSMISSION_AV                       998 non-null    int64
 30  TRANSMISSION_AV6                      998 non-null    int64
 31  TRANSMISSION_AV7                      998 non-null    int64
 32  TRANSMISSION_AV8                      998 non-null    int64
 33  TRANSMISSION_M5                       998 non-null    int64
 34  TRANSMISSION_M6                       998 non-null    int64
 35  TRANSMISSION_M7                       998 non-null    int64
 36  VEHICLECLASS_COMPACT                  998 non-null    int64
 37  VEHICLECLASS_FULL-SIZE                998 non-null    int64
 38  VEHICLECLASS_MID-SIZE                 998 non-null    int64
 39  VEHICLECLASS_MINICOMPACT              998 non-null    int64
 40  VEHICLECLASS_MINIVAN                  998 non-null    int64
 41  VEHICLECLASS_PICKUP TRUCK - SMALL     998 non-null    int64
 42  VEHICLECLASS_PICKUP TRUCK - STANDARD  998 non-null    int64
 43  VEHICLECLASS_SPECIAL PURPOSE VEHICLE  998 non-null    int64
 44  VEHICLECLASS_STATION WAGON - MID-SIZE 998 non-null    int64
 45  VEHICLECLASS_STATION WAGON - SMALL    998 non-null    int64
 46  VEHICLECLASS_SUBCOMPACT               998 non-null    int64
 47  VEHICLECLASS_SUV - SMALL              998 non-null    int64
 48  VEHICLECLASS_SUV - STANDARD           998 non-null    int64
 49  VEHICLECLASS_TWO-SEATER               998 non-null    int64
 50  VEHICLECLASS_VAN - CARGO              998 non-null    int64
 51  VEHICLECLASS_VAN - PASSENGER          998 non-null    int64
dtypes: float64(4), int64(46), object(2)
memory usage: 413.2+ KB
```

✅ 5. Preprocesamiento y escalado

Selecciona tus features (X) y la variable objetivo (y). Aplica StandardScaler para normalizar los datos pero ahora con más features.

```
from sklearn.preprocessing import StandardScaler

features = df_cleaned.select_dtypes(include=['float64', 'int64']).columns.tolist()
features = [col for col in features if col not in ['CO2EMISSIONS', 'MODELYEAR']]
target = 'CO2EMISSIONS'

X = df_cleaned[features]
y = df_cleaned[target]

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

✅ 6. División de datos

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size=0.2, random_state=42)
```

✅ 7. Entrenamiento de modelos

- Regresión Lineal Múltiple (base)
- Regresión Polinómica

- Árbol de Decisión
- Random Forest

Regresión Lineal Múltiple (base)

```
from sklearn.linear_model import LinearRegression

LRM = LinearRegression()
LRM.fit(X_train, y_train)
```

```
LinearRegression
LinearRegression()
```

Regresión Polinómica

```
from sklearn.preprocessing import PolynomialFeatures

poly = PolynomialFeatures(degree=2)
X_train_poly = poly.fit_transform(X_train)
X_test_poly = poly.transform(X_test)

PRM = LinearRegression()
PRM.fit(X_train_poly, y_train)
```

```
LinearRegression
LinearRegression()
```

Árbol de Decisión

```
from sklearn.tree import DecisionTreeRegressor

DTR = DecisionTreeRegressor(random_state=42)
DTR.fit(X_train, y_train)
```

```
DecisionTreeRegressor
DecisionTreeRegressor(random_state=42)
```

Random Forest

```
from sklearn.ensemble import RandomForestRegressor

RFR = RandomForestRegressor(n_estimators=100, random_state=42)
RFR.fit(X_train, y_train)
```

```
RandomForestRegressor
RandomForestRegressor(random_state=42)
```

✅ 8. Evaluación de modelos

Se utilizarán métricas como R^2, MAE, MSE y RMSE. También se aplicará validación cruzada para comparar el rendimiento.

```
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score, root_mean_squared_error
from sklearn.model_selection import cross_val_score
```

Regresión Lineal Múltiple (base)

```
y_pred_LRM = LRM.predict(X_test)

print("R²:", r2_score(y_test, y_pred_LRM))
print("MAE:", mean_absolute_error(y_test, y_pred_LRM))
print("MSE:", mean_squared_error(y_test, y_pred_LRM))
print("RMSE:", root_mean_squared_error(y_test, y_pred_LRM))

scores_LRM = cross_val_score(LRM, X_scaled, y, cv=5)
print("Validación Cruzada (R²):", scores_LRM.mean())
```

```
R²: 0.9947186921459527
MAE: 1.8035473806961366
MSE: 19.326853140868096
RMSE: 4.396231697814401
Validación Cruzada (R²): 0.9942108209747442
```

Regresión Polinómica

```
y_pred_PRM = PRM.predict(X_test_poly)

print("R²:", r2_score(y_test, y_pred_PRM))
print("MAE:", mean_absolute_error(y_test, y_pred_PRM))
print("MSE:", mean_squared_error(y_test, y_pred_PRM))
print("RMSE:", root_mean_squared_error(y_test, y_pred_PRM))

scores_PRM = cross_val_score(PRM, X_scaled, y, cv=5)
print("Validación Cruzada (R²):", scores_PRM.mean())
```

```
R²: 0.997452987127331
MAE: 0.9229639628514237
MSE: 9.320748780105633
RMSE: 3.0529901375709736
Validación Cruzada (R²): 0.9942108209747442
```

Árbol de Decisión

```
y_pred_DTR = DTR.predict(X_test)

print("R²:", r2_score(y_test, y_pred_DTR))
print("MAE:", mean_absolute_error(y_test, y_pred_DTR))
print("MSE:", mean_squared_error(y_test, y_pred_DTR))
print("RMSE:", root_mean_squared_error(y_test, y_pred_DTR))

scores_DTR = cross_val_score(DTR, X_scaled, y, cv=5)
print("Validación Cruzada (R²):", scores_DTR.mean())
```

```
R²: 0.9992157360833325
MAE: 0.39
MSE: 2.87
RMSE: 1.6941074346097416
Validación Cruzada (R²): 0.980611278360529
```

Random Forest

```
y_pred_RFR = RFR.predict(X_test)

print("R²:", r2_score(y_test, y_pred_RFR))
print("MAE:", mean_absolute_error(y_test, y_pred_RFR))
print("MSE:", mean_squared_error(y_test, y_pred_RFR))
print("RMSE:", root_mean_squared_error(y_test, y_pred_RFR))

scores_RFR = cross_val_score(RFR, X_scaled, y, cv=5)
print("Validación Cruzada (R²):", scores_RFR.mean())
```

```
R²: 0.9978510157611361
MAE: 0.9259999999999993
MSE: 7.864170000000006
RMSE: 2.8043127500334206
Validación Cruzada (R²): 0.9857365180681814
```

✅ 9. Comparación de resultados

Tabla para comparativo entre modelos.

```python
def compare_models(models, X_train, y_train, X_test, y_test, X_train_poly, X_test_poly):
    results = []
    for name, model in models.items():
        # Train the model with the correct feature set
        if name == 'Regresión Polinómica':
            model.fit(X_train_poly, y_train)
        else:
            model.fit(X_train, y_train)

        # Make predictions based on the model type and test features
        if name == 'Regresión Polinómica':
            y_pred = model.predict(X_test_poly)
        else:
            y_pred = model.predict(X_test)

        # Calculate test set metrics
        r2 = r2_score(y_test, y_pred)
        mae = mean_absolute_error(y_test, y_pred)
        mse = mean_squared_error(y_test, y_pred)
        rmse = root_mean_squared_error(y_test, y_pred)
        cross_val_r2 = cross_val_score(model, X_scaled, y, cv=5).mean()

        # Append results
        results.append([name, r2, mae, mse, rmse, cross_val_r2])

    results_df = pd.DataFrame(results, columns=['Modelo', 'R²', 'MAE', 'MSE', 'RMSE', 'Cross-Validation R²'])
    return results_df

models = {
    'Regresión Lineal Múltiple (base)': LRM,
    'Regresión Polinómica': PRM,
    'Árboles de Decisión': DTR,
    'Random Forest': RFR
}
# Call the function with all necessary training and test data
results_df = compare_models(models, X_train, y_train, X_test, y_test, X_train_poly, X_test_poly)
display(results_df)
```

	Modelo	R²	MAE	MSE	RMSE	Cross-Validation R²
0	Regresión Lineal Múltiple (base)	0.994719	1.803547	19.326853	4.396232	0.994211
1	Regresión Polinómica	0.997453	0.922964	9.320749	3.052990	0.994211
2	Árboles de Decisión	0.999216	0.390000	2.870000	1.694107	0.980611
3	Random Forest	0.997851	0.926000	7.864170	2.804313	0.985737

Next steps: Generate code with `results_df` | View recommended plots | New interactive sheet

📊 Gráfico de Barras Agrupadas

Este gráfico muestra claramente cómo se comporta cada modelo en cada métrica:

```
# Gráfico de Barras Agrupadas
fig, ax = plt.subplots(figsize=(10, 6))
x = np.arange(len(results_df))
width = 0.155

for i, metric in enumerate(['R²', 'MAE', 'MSE', 'RMSE', 'Cross-Validation R²']):
    ax.bar(x + i * width, results_df[metric], width, label=metric)

    # Agregar valores en las barras
    for j, value in enumerate(results_df[metric]):
        ax.text(x[j] + i * width, value, f'{value:.2f}', ha='center', va='bottom')

ax.set_xlabel('Modelo')
ax.set_ylabel('Métricas')
ax.set_title('Comparación de Métricas de Modelos')
ax.set_xticks(x + width)
ax.set_xticklabels(results_df['Modelo'])
ax.legend()

plt.show()
```

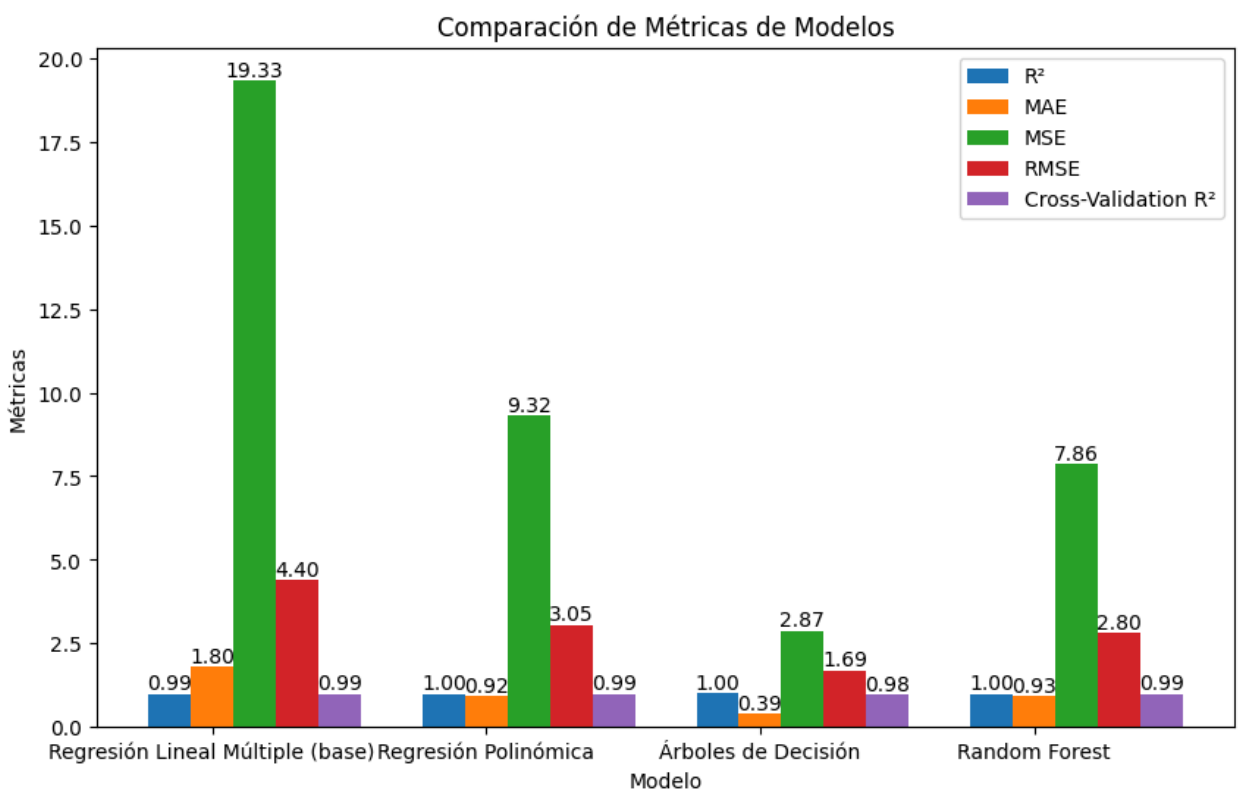

Gráfico de Radar (Spider Chart)

Este gráfico permite ver de forma intuitiva qué tan equilibrado es el rendimiento de cada modelo en todas las métricas (normalizadas):

```
from math import pi

# Copiar el DataFrame original
df_radar = results_df.copy()

# Normalizar e invertir las métricas de error (para que 1 sea mejor)
df_radar['MAE'] = 1 - df_radar['MAE'] / df_radar['MAE'].max()
df_radar['MSE'] = 1 - df_radar['MSE'] / df_radar['MSE'].max()
df_radar['RMSE'] = 1 - df_radar['RMSE'] / df_radar['RMSE'].max()

# Normalizar R²
df_radar['R²'] = df_radar['R²'] / df_radar['R²'].max()

```

```
# Normalizar Validación Cruzada R²:
df_radar['Cross-Validation R²'] = df_radar['Cross-Validation R²'] / df_radar['Cross-Validation R²'].max()

# Seleccionar las métricas a graficar (en orden de preferencia visual)
metricas = ['R²', 'MAE', 'MSE', 'RMSE', 'Cross-Validation R²']

# Etiquetas y ángulos
labels = metricas
num_vars = len(labels)
angles = [n / float(num_vars) * 2 * pi for n in range(num_vars)]
angles += angles[:1]  # Cerrar el círculo

# Crear gráfico
fig, ax = plt.subplots(figsize=(8,8), subplot_kw=dict(polar=True))

# Graficar cada modelo
for i, row in df_radar.iterrows():
    valores = row[metricas].tolist()
    valores += valores[:1]  # Cerrar el círculo
    ax.plot(angles, valores, label=row['Modelo'])
    ax.fill(angles, valores, alpha=0.1)

# Configurar etiquetas y título
ax.set_xticks(angles[:-1])
ax.set_xticklabels(labels)
ax.set_title('Radar de Métricas Normalizadas por Modelo', y=1.1)
ax.legend(loc='upper right', bbox_to_anchor=(1.3, 1.1))
plt.tight_layout()
plt.show()
```

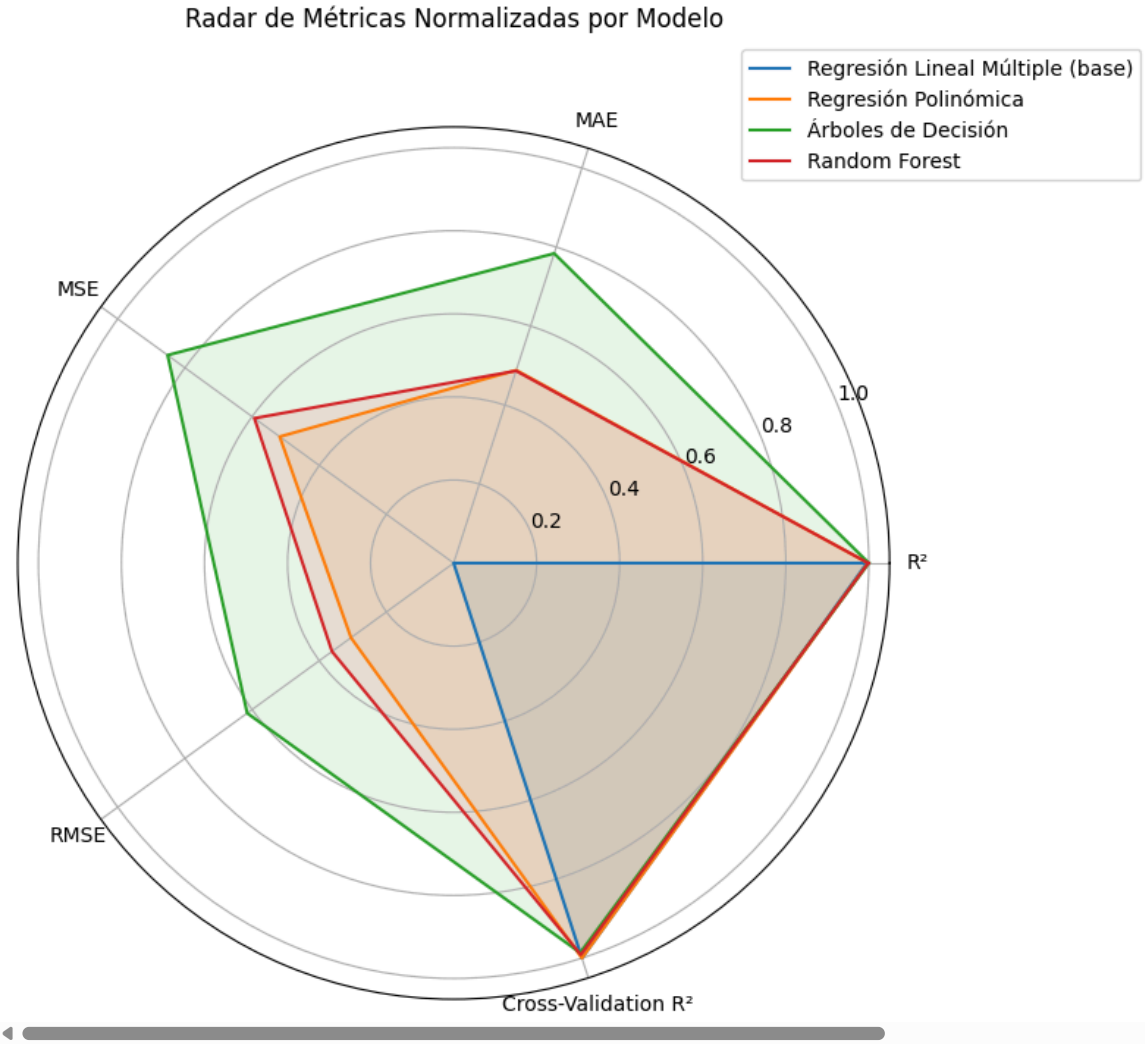

🧠 Observaciones:

Árbol de Decisión destaca con el mejor R^2 y los errores más bajos en el conjunto de prueba, pero su validación cruzada es la más baja, lo que sugiere posible sobreajuste ⚠️.

Random Forest ofrece un excelente equilibrio entre precisión y generalización, siendo una opción muy robusta 💪.

Regresión Polinómica mejora significativamente respecto a la lineal, especialmente en MAE y MSE, sin perder capacidad de generalización 🎯.

Regresión Lineal Múltiple, aunque es la más simple, muestra un rendimiento sólido, pero claramente superado por los modelos más complejos 📉.

✅ 10. Conclusiones y recomendaciones

✅ Conclusiones

Tras ampliar el preprocesamiento y enriquecer el conjunto de características, se evaluaron múltiples modelos de regresión. A continuación, se resumen las principales conclusiones:

🔍 Comparación de Modelos

Regresión Lineal Múltiple: Aunque fue el modelo base, su rendimiento fue superado por modelos más complejos. Sin embargo, sigue siendo útil como referencia por su simplicidad y rapidez de entrenamiento.

Regresión Polinómica: Mostró una mejora significativa en precisión respecto al modelo lineal, especialmente en MAE y MSE. Es una buena opción cuando se sospecha de relaciones no lineales entre las variables.

Árbol de Decisión: Obtuvo el mejor desempeño en el conjunto de prueba, pero su baja puntuación en validación cruzada sugiere un posible sobreajuste. Ideal para exploración inicial o cuando se requiere interpretabilidad.

Random Forest: Ofreció el mejor equilibrio entre precisión y capacidad de generalización. Es el modelo más robusto y confiable en este análisis, recomendado para producción o toma de decisiones.

📌 Recomendaciones

Para aplicaciones donde la precisión es crítica, se recomienda utilizar **Random Forest**.

Si se busca un modelo explicable y rápido, la **Regresión Lineal Múltiple** sigue siendo válida.

Se sugiere realizar una búsqueda de hiperparámetros (**GridSearchCV** o **RandomizedSearchCV**) para afinar aún más los modelos más complejos.